

高吞吐状况下斗鱼搜索 引擎优化之路

白凡@尚德机构 2017-11-04, weibo:阿bia123

Nov 4, 2017

关于我

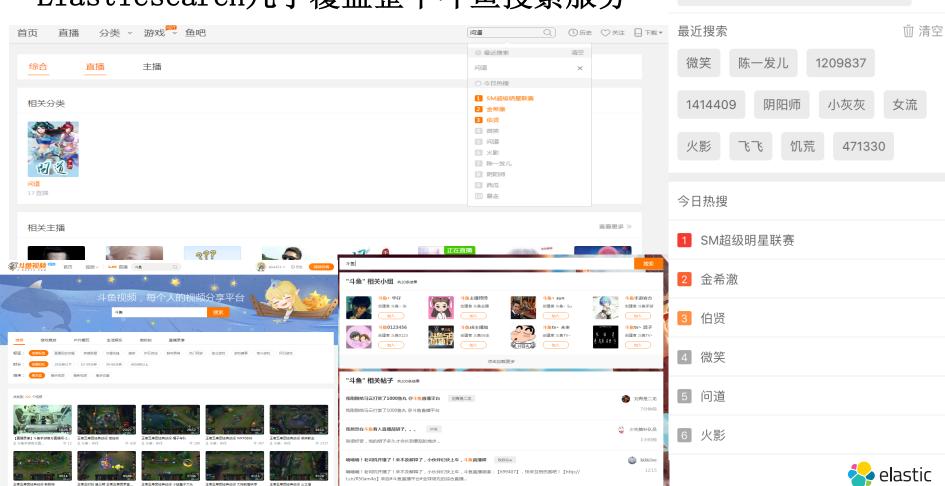
2015年1月进入斗鱼,一直从事斗鱼的搜索服务搭建。

2017年10月加入尚德机构。

主要项目包含,斗鱼主站,移 动端、鱼秀、鱼吧、点播站等 搜索服务。



Elasticsearch几乎覆盖整个斗鱼搜索服务



●●●●● 中国联诵 令

下午5:03

直播▼ 搜索房间 / 主播 / 分类

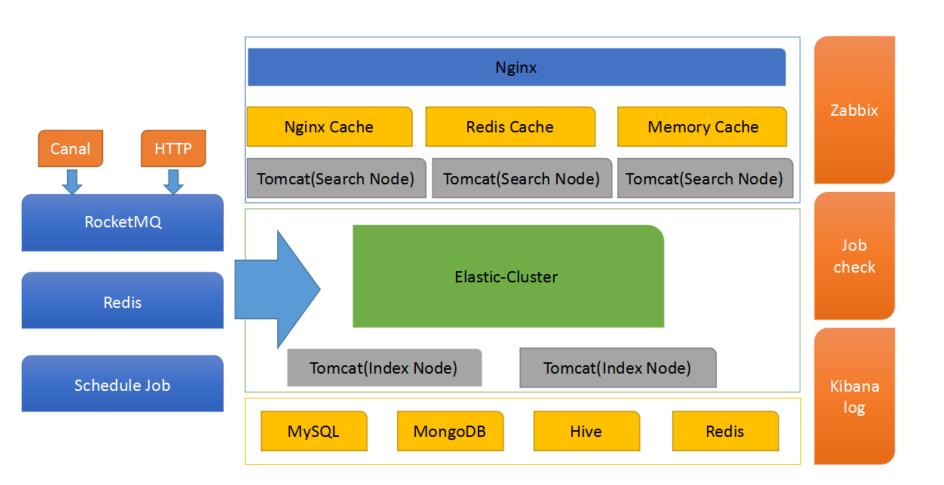
♠ ♥ 58%

取消

主要内容

- 技术架构
- 优化之路
- ES应用拓展
- 常见问题





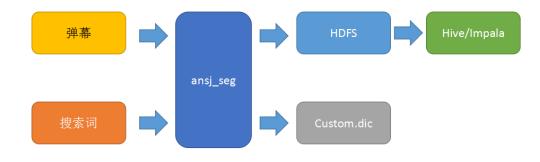
如何丰富自定义词库?

主要来源于斗鱼"弹幕"以及搜索词

采用Ansj中文分词器

HDFS,离线统计分析

Coustom.dic, 供索引分词





自定义分词器

场景:

斗鱼直播间有房间描述,如"五五开"的直播间, 其描述可能就会有"五五开,电竞卢本伟,大神"等。且对于描述的权重比例很高。

而对于搜索业务,我们不希望搜索 "五","开","卢本伟"等词能匹配到,仅在搜索 "五五开","电竞卢本伟"时返回结果。

因此,whitespace analyzer加入基于","的 pattern tokenizer。实现空格和逗号分词。

创建mapping时,analyzer采用 whitespace,search_analyzer仍然使用ik,搜索 使用termQuery

```
"settings" : {
   "analysis" : {
      "analyzer" : {
         "pattern analyzer" : {
            "tokenizer" : "dy pattern"
         "pinyin analyzer" : {
            "tokenizer" : "dy pinyin"
         "ik smart" : {
            "tokenizer" : "dy ik"
         "douyu_analyzer" : {
            "tokenizer" : "dy ngram"
      "tokenizer" : {
         "dy pinyin" : {
            "type": "pinyin",
            "keep_full_pinyin" : false
         "dy pattern": {
            "type": "pattern",
            "pattern": ","
         "dy ik" : {
            "type" : "lowercase"
         "dy ngram" : {
            "type": "ngram",
           "min gram": 1,
            "max gram": 20,
            "token chars" : [
               "letter",
               "digit",
               "punctuation",
              "symbol"
```



Java API开发

BoolQuery多维度查询

维度权重比例不一,权重值配置中心统一调度

```
OuervBuilder
                              = QueryBuilders.termQuery(
                           ", sk).boost(
        (float) OceanDataCommonConfig
                .getValueInteger(
                                                               ));
OueryBuilder queryRoomNameFuzzy = OueryBuilders.prefixOuery(
QueryBuilder
                         = QueryBuilders.matchQuery("
QueryBuilder
                        = QueryBuilders.termQuery("
        .boost((float) OceanDataCommonConfig
                                                    "));
                .getValueInteger("
OuervBuilder (
                       = QueryBuilders.termQuery("
        .boost((float) OceanDataCommonConfig
                .getValueInteger("
BoolQueryBuilder shouldQuery = QueryBuilders.boolQuery()
        .should(
        .should(
        .should(
        .should(
        .should(
QueryBuilder queryStatus = QueryBuilders.termQuery("
BoolQueryBuilder mustQuery = QueryBuilders.boolQuery()
        .must(shouldQuery).must(queryStatus);
```



增量索引

- 由于斗鱼语言的异构性, PHP,C++,Java..., 所以索引同步显得非常麻烦, 在这里,分享目前斗鱼搜索的几个增量索引的方法。
- RocketMQ,实时性、稳定性最好,可复用,需要中间插件,比较推荐。数据源为Canal解析binlog,亦或前端直接通过HTTP请求POST增量数据。只要设置不同的Group,可共同消费。
- Redis队列,实时性、稳定性好,不可复用,需要中间插件。采用Redis队列进行消费,但不可复用,只能一个服务端消费,且如果未做持久化、一旦Redis挂掉,数据不可恢复。
- 定时任务,无需中间件,但实时性、稳定性不好。通过更新时间定时更新增量索引,一旦任务挂掉,时间点一过,则不可恢复。且对更新时间非常敏感,必须为写入数据库时间。



- 集群升级,原因不外乎其二:
- 1.现有版本性能已经不能满足当前业务需求
- 2.新版本的某些接口或者功能很诱人

- 斗鱼升级主要是,业务扩展开,全站搜索ES化,PV上涨过快,搜索接口压力加大。
- 除了加机器,换SSD,水平加data node,配合ELK体系一起升级5.x
- String->text,keyword IK->ik_smart,ik_max_word
- head cerebro(前身kopf)成为独立server



• 分词系统升级,5.x之后,分词配置不在elasticsearch.yml。

- 最主要用ngram分词替换掉了令人头疼的wildcard查询。
- 弊端在于会产生大量分词文件。

• 控制分片数量,太多并不意味着会更好,根据实际的性能要求调整。

• mapping一旦创建无法更改,建议创建一个mapping时,多预留备份字段。



• 索引均匀写入磁盘,分摊磁盘I/O压力

"Hodelattindek. FT					
#					
#	Paths				
#					
# Path to directory where to s #	tore the data (separate multiple loca	itions by comma):			
path.data: /mnt/sdb/ #	-data1,/mnt/sdc,	data1,/mnt/sdd,	-data1,/mnt/sde	'ata1,/mnt/sdf	data1
# Path to log files: #					
#path.logs: /path/to/logs					



· 记录所有慢查询,同样无法再ES.yml里配置

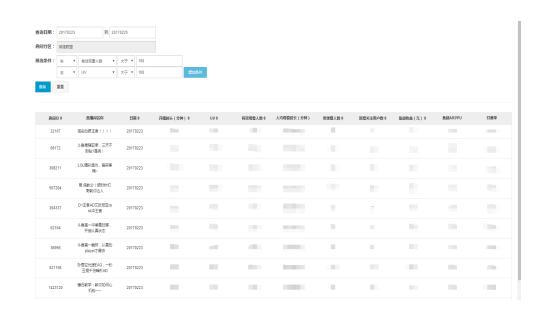


ES应用拓展

• 目前主流ELK, Elasticsearch。

• Elasticsearch用于数据可视化 展示,可以轻松实现多维度逻辑查询。

• Elasticsearch用于类似天梯匹配(推荐)系统,可依靠boost 轻松调节业务逻辑。





常见问题

• 数据库和ES 数据同步的方案?

• 集群设置多少分片,设置多少数据节点,master 节点问题?

• ES在高并发环境下的可用性?



Questions?!



Thanks!

